ПРОЕКТНОЕ ПРЕДЛОЖЕНИЕ · ЗАДАНИЕ 1 — ПРОБЛЕМА И ДАТАСЕТ

Tender Risk ML

Прогнозирование проблемных государственных закупок в Казахстане по открытым данным

Автор
Азиз Абдулин

Репозиторий
github.com/awzwz/tender-risk-ml

Источник данных
OWS v3 API · goszakup

Задача
Классификация + NLP

1,8 млн
закупок в год на goszakup.gov.kz

630 762
закупки в датасете (I кв. 2024)

≈ 23%
контрактов расторгнуто или не заключено

5
связанных таблиц: закупки, лоты, заявки, договоры, РНУ

01 Название проекта

> **Tender Risk ML — прогнозирование проблемных государственных закупок в Казахстане по открытым данным о закупках**

02 Описание проблемы

Через систему государственных закупок Казахстана (goszakup.gov.kz) проходит около **1,8 млн закупок в год** — 12,9 млн за всё время по состоянию на сентябрь 2026 года и более 40 млн заявок поставщиков. На них приходится значительная доля государственного бюджета.

Каждая закупка, лот, заявка и договор публикуются через открытый **OWS v3 GraphQL API**. Однако контролирующие органы, журналисты и аудиторы работают вручную: за год они способны проверить лишь несколько сотен закупок. При этом признаки проблемной закупки — единственный участник, неправдоподобная скидка, конкурентная процедура, которая «не состоялась» и ушла к единственному поставщику, поставщик с историей расторгнутых договоров — разбросаны по нескольким связанным таблицам и не видны на уровне отдельной записи.

На практике это приводит к тому, что значительная часть договоров заканчивается плохо. В выборке договоров за 2024 финансовый год примерно **каждый пятый был расторгнут или так и не заключён**, а около 7% **закупок были отменены** после публикации. Каждый такой случай — это повторная процедура, задержка поставки товаров или услуг и часто потерянные бюджетные средства. Если выявлять закупки, которые с высокой вероятностью сорвутся, *до* того как они сорвутся, контролирующий орган сможет сосредоточить ограниченные ресурсы там, где это действительно важно.

В предыдущем инженерном проекте автора (Tender Radar) эта задача решалась с помощью 31 вручную написанного правила оценки риска. Правила прозрачны, но произвольны: их пороги подбирались интуитивно, и не было способа проверить, закончилась ли «рискованная» закупка

на самом деле плохо. Данный проект заменяет интуицию **моделью с учителем, обученной на реально наблюдаемых исходах**, а правила используются лишь как кандидаты в признаки.

03 Цель проекта

Построить и оценить классификатор машинного обучения, который, используя только информацию, доступную на момент публикации закупки и определения победителя, предсказывает, будет ли у закупки **проблемный исход** — то есть будет ли итоговый договор расторгнут или не заключён, — и определить, какие характеристики закупки сильнее всего связаны с таким исходом.

04 Задачи проекта

1 **Сбор датасета** A1

Выгрузить из OWS v3 API связанный срез закупок, опубликованных в I квартале 2024 года, — закупки, лоты, заявки, договоры и реестр недобросовестных поставщиков — и опубликовать его как воспроизводимый документированный датасет (скрипт сбора + словарь данных).

2 **Подготовка данных и EDA** A2

Очистить и нормализовать данные (пропуски, дубликаты, форматы валют и дат, нормализация текста названий лотов на русском и казахском), исследовать распределения и баланс классов, строго определить целевую переменную и выполнить **разбиение на train/validation/test по времени**, исключающее утечку данных.

3 **Построение признаков** A2

Сформировать табличные признаки (цена, число участников, скидка, способ закупки, история заказчика и поставщика, 31 индикатор Tender Radar) и текстовые признаки (TF-IDF по названиям и описаниям лотов).

4 **Базовая модель и оценка** MIDTERM

Обучить и сравнить классические модели (логистическая регрессия, Random Forest, градиентный бустинг) на табличных признаках и TF-IDF; привести ROC-AUC, PR-AUC и F1 на отложенном тестовом периоде с интерпретацией важности признаков.

5 **Улучшение модели** A3

Подобрать гиперпараметры лучшей классической модели и добавить текстовую ветку — **дообучить предобученный мультиязычный трансформер** (transfer learning с `xlm-roberta-base` / `rubert-tiny2`) на описаниях лотов; сравнить его с табличной моделью и объединить их в ансамбль.

05 Тип AI-задачи

✓ Классификация | + NLP-компонент | Регрессия | Кластеризация | Компьютерное зрение | Генеративный ИИ

Бинарная классификация (обучение с учителем) на табличных данных с **NLP-компонентом**: названия и описания лотов — это свободный текст на русском и казахском языках. В базовой модели он векторизуется с помощью TF-IDF, а на этапе дообучения кодируется предобученным трансформером. Поскольку положительных примеров меньшинство (~20%), при оценке основной упор делается на **ROC-AUC, PR-AUC и F1**, а не на accuracy.

06 Датасет

6.1 Источник и доступ

- **Источник:** OWS v3 GraphQL API, `ows.goszakup.gov.kz/v3/graphql` — официальный интерфейс открытых данных портала государственных закупок. Доступ по персональному API-токену (действует до 13.11.2026). Данные публичные.
- **Охват:** все закупки с `publishDate` в диапазоне **01.01.2024 … 31.03.2024 — 630 762 закупки**, около 35% от 1 818 344 закупок 2024 финансового года, — и все связанные с ними записи. I квартал 2024 года выбран потому, что у каждого договора было больше двух лет, чтобы дойти до финального статуса, — метка исхода уже устоялась.
- **Сбор:** `src/collect.py` — возобновляемая пагинация `limit/after`, хранение в JSONL и Parquet. Срез данных публикуется как release-asset на GitHub; скрипт позволяет воспроизвести его с нуля.

6.2 Сущности



Рисунок 1. Связанные таблицы. Всё привязано к идентификатору закупки; реестр РНУ присоединяется по БИН поставщика.

ТАБЛИЦА	ЕДИНИЦА	СТРОК (I КВ. 2024)	КЛЮЧЕВЫЕ ПОЛЯ
`trd_buy`	закупка	**630 762**	id, название, способ закупки, статус, общая сумма, число лотов, БИН заказчика, БИН победителя, даты публикации / начала / окончания
`lots`	лот	**~1 100 000**	id закупки, название RU/KZ, описание, сумма, признак демпинга, код КТРУ, статус
`trd_app`	заявка	**~2 500 000**	id закупки, БИН поставщика, цена и скидка по каждому лоту
`contracts`	договор	**~470 000**	id закупки, БИН поставщика, статус, причина расторжения, суммы, плановые / фактические даты исполнения
`rnu`	запись о поставщике	**17 638**	БИН поставщика, даты включения в реестр и исключения из него (за всё время)

Число строк trd_buy точное (выгружено полностью). Оценка для lots экстраполирована по первым 195 000 выгруженных закупок (1,8 лота на закупку), остальные — по пилотной выборке. Точные цифры будут приведены в А2.

6.3 Целевая переменная

ОСНОВНОЙ TARGET

`contract_failed` — бинарный, одна строка на закупку

1, если договор по закупке имеет статус *Расторгнут* (код 350), *Ожидание расторжения* (345) или *Не заключён* (330); **0**, если он *Действует*, *Изменён* или *Исполнен*. Закупки без договоров исключаются из основной задачи.



Сорвано · 350/345/330 · **метка 1** · Изменён · 455 · Действует / исполнен · 190/390/460 · 6% · Прочее · 3%

Выборка из первых 400 договоров 2024 финансового года.

Вспомогательные метки сохраняются в датасете для расширенного анализа:

`tender_cancelled`
~7% · статус закупки «Отменено» (430) или «Отказ от закупки» (410)

`winner_in_rnu`
редко · победитель позже попал в реестр недобросовестных поставщиков

`single_source_after_failed`
~19% · закупка из одного источника после несостоявшейся процедуры

Почему наблюдаемый исход, а не риск-скор на правилах: модель, обученная на метках, которые порождены вручную написанными правилами, просто выучит эти правила. Расторжение договора — реальное, независимо зафиксированное событие, поэтому качество модели можно измерить честно, а правила — проверить в роли признаков.

6.4 Контроль утечки данных

В признаки попадают только поля, известные на момент публикации и определения победителя: атрибуты закупки и лотов, заявки, личность победителя, а также *история* заказчика и поставщика **строго до** даты публикации закупки. Поля исполнения договора (`faktSum`, `faktExecDate`, статус) используются только для метки. Разбиение выполняется по времени — **обучение на январе–феврале, валидация и тест на марте 2024 года**, — чтобы информация из будущего не попадала в обучение.

6.5 Группы признаков (предварительно)

Закупка
Способ закупки, тип предмета, общая сумма, число лотов, плановая длительность, признак повторной закупки, признак единого организатора, признаки строительства / лёгкой промышленности, регион (КАТО).

Конкуренция
Число участников, число заявок на лот, скидка победителя, признак демпинга, разброс цен в заявках.

Текст
TF-IDF (словесные и символьные n-граммы) по названиям и описаниям лотов; эмбеддинги трансформера в А3.

История поставщика / заказчика
Считается строго до даты публикации: число предыдущих договоров, доля расторгнутых, доля побед у того же заказчика, наличие в РНУ.

Индикаторы-правила
31 индикатор Tender Radar, переписанный на pandas и используемый как входные признаки, а не как метки.

07 План и результаты этапов

НЕДЕЛИ 1–2

A1 · Проблема и датасет

Это предложение; выгружен и опубликован срез данных за I кв. 2024.

НЕДЕЛИ 3–4

A2 · Подготовка данных

Структура, пропуски, дубликаты, очистка, EDA, визуализации, признаки и target, разбиение по времени; краткий отчёт.

НЕДЕЛЯ 5

Midterm · Базовая модель

Логистическая регрессия + Random Forest, ROC-AUC / PR-AUC / F1, презентация, обоснование выбора модели.

ПОСЛЕ МИДТЕРМА

A3 · Тюнинг и дообучение

LightGBM, подбор гиперпараметров, дообученный трансформер на текстах лотов, ансамбль; результаты экспериментов.

08 Ожидаемые результаты

Открытый датасет

Публичный воспроизводимый датасет закупок за I кв. 2024 с документированной меткой исхода.

Более точный классификатор

ROC-AUC заметно выше, чем у риск-скора на правилах, который служит базой для сравнения.

Факторы риска

Ранжированный список характеристик закупки, сильнее всего связанных со срывом договора, — практически полезный результат для аудитора.

09 Риски и способы их снижения

РИСК	КАК СНИЖАЕМ
Срок действия API-токена истекает 13.11.2026	Полный срез данных выгружается в сентябре; вся дальнейшая работа идёт офлайн.
Дисбаланс классов	Метрики PR-AUC / F1; веса классов; подбор порога.
Шум в метке — расторжение «по соглашению сторон» не всегда означает срыв	Сохраняем коды причин расторжения; приводим результаты на строгом подмножестве (расторжение за нарушение / договор не заключён) как анализ чувствительности.
Тексты на двух языках	Мультиязычные модели (XLM-R); лоты только на казахском обрабатываются через русское название, которое есть почти всегда.
Вычислительные ресурсы для дообучения трансформера	`rubert-tiny2` обучается на CPU / в Colab; для более крупных моделей — LoRA.