Лучшая модель или лучшая информация? Бустинг, дообученные кодировщики и LLM с QLoRA для прогноза срыва договоров госзакупок

Азиз Абдулин · октябрь 2026 · Код и ноутбуки: github.com/awzwz/tender-risk-ml (notebooks/04–07) · сдаётся английская версия

1. Задача и постановка

Проект предсказывает в момент выбора победителя госзакупки в Казахстане, **сорвётся** ли договор — будет расторгнут или не заключён, — чтобы надзорные органы могли упорядочить закупки для проверки. Данные — все 358 789 закупок I квартала 2024 года на национальном портале (OWS v3 API), по которым был договор; 6,6 % из них сорвались. Разбиение по времени: train = январь–февраль, validation = 1–15 марта (все решения), test = 16–31 марта (оценивается один раз). Метрика выбора — **PR-AUC** (average precision), потому что проверяющий работает с верхом ранжированного списка; также приводятся ROC-AUC, F1 при пороге с validation, точность среди 1 % самых рискованных (*P@1%*), полнота в топ-5 % и Brier, а каждая разница на test идёт с парным бутстрэп-интервалом 95 % (1 000 перевыборок). Baseline мидтерма — логистическая регрессия с весами классов на 20 признаках — дал PR-AUC **0,262**. Assignment 3 спрашивает, насколько это можно улучшить и, главное, *откуда* берётся улучшение: от лучшей модели, её настройки или новой информации о закупке.

2. Методы

- **Сравнение моделей и подбор (ноутбук 04).** Логистическая регрессия, случайный лес, LightGBM (Ke et al., 2017) и CatBoost (Prokhorenkova et al., 2018) на одних и тех же 20 признаках. Логистическая регрессия настраивалась полным перебором (42 конфигурации, один заданный фолд train → validation); остальные три — байесовской оптимизацией Optuna/TPE (Akiba et al., 2019; 30 / 50 / 30 попыток, ранняя остановка по PR-AUC на validation для бустинга). Кросс-валидация со случайными фолдами отвергнута, потому что смешивает периоды. Отдельно измерен эффект порога решения и калибровки вероятностей (масштабирование Платта, изотоническая регрессия).
- **Transfer learning и fine-tuning на названиях лотов (05a/05b).** Три замороженных русских кодировщика (rubert-tiny2 29 млн, multilingual-e5-small 118 млн, rubert-base-cased 178 млн параметров) использованы как извлекатели признаков с линейной пробой и, в виде 32 главных компонент, внутри табличной модели. rubert-tiny2 дообучена полностью (все 29,2 млн весов; AdamW, weight decay 0,01; шаг обучения из {2e-5, 5e-5, 1e-4}; линейный прогрев 6 %; батч 64; 3 эпохи с выбором лучшей на validation; кросс-энтропия с весами классов; ≤ 20 строк на уникальный текст; три зерна). Оценки вне фолда (5 фолдов, сгруппированных по тексту) позволили честный стекинг. Ориентир без переноса знаний — модель TF-IDF.
- **LLM с QLoRA (06).** Qwen2.5-1.5B читала короткую русскую «карточку» закупки с теми же фактами, что у финальной табличной модели, плюс названия лотов, с головой классификации на два класса. Базовые веса заморожены в 4 битах NF4 (двойное квантование, вычисления в fp16; Dettmers et al., 2023); обучались адаптеры LoRA (Hu et al., 2022) с r = 16, α = 32, dropout 0,05 на всех семи линейных проекциях (q, k, v, o, gate, up, down) и голова целиком: **18 467 840 обучаемых параметров (1,2 %)**. Paged AdamW 8 бит, шаг 2e-4 с косинусным снижением, эффективный батч 64, одна эпоха на 40 000 закупок train (выборка срывов 1 : 3), на бесплатной T4 в Kaggle (2,2 ч обучение, 1,3 ч предсказание). Полному дообучению понадобилось бы ≈ 25 ГБ без активаций; QLoRA заняла на пике 2,7 ГБ. Контроли: LightGBM на тех же 40 000 строк и той же информации и на всём train.
- **Финальная модель (07).** 61 признак: 20 признаков мидтерма, 32 текстовые компоненты и 9 версий без утечки правил-индикаторов прототипа Tender Radar — «красных флагов» в смысле Fazekas & Kocsis (2020) — (история «заказчик–поставщик», плановая цена за единицу к рынку), все посчитаны только по сведениям, датированным раньше публикации. Три кандидата сравнивались на validation; абляции, SHAP (точный TreeSHAP; Lundberg et al., 2020) и подъём по сегментам объясняют результат.

3. Результаты

3.1 Семейство модели против подбора

20 признаков мидтерма, период test	по умолчанию	настроена	прирост от подбора [95 %]	что решило в поиске
Логистическая регрессия	0,262	0,280	+0,018 [+0,015; +0,022]	отказ от весов классов (L1, C = 0,1)
Случайный лес	0,249	0,290	+0,041 [+0,033; +0,049]	доля признаков на разбиение (86 % разброса), глубина 13
LightGBM	0,303	0,304	+0,001 [−0,007; +0,010]	только шаг обучения; ранняя остановка оставляет ~9 деревьев
CatBoost	**0,288**	**0,311**	**+0,023 [+0,016; +0,030]**	**глубина 8, без весов классов**

Смена семейства модели — самый большой прирост при фиксированных признаках: настроенный CatBoost даёт 0,311 против 0,262 (+0,049 [+0,039; +0,059]); две библиотеки бустинга заканчивают в пределах 0,007 друг от друга. Подбор помогает, когда настройки по умолчанию плохие (полностью выращенные деревья случайного леса переобучаются и оказываются *ниже* линейного baseline), и ничего не даёт для LightGBM, у которого PR-AUC на validation достигает пика после горстки деревьев — поиск в итоге выбирает, где остановиться. Кривые сходимости выходят на плато примерно после 15 попыток. Порог, оптимальный по F1 на validation, поднимает полноту на test с 5 % (порог 0,5) до 41 % при точности 34 %; масштабирование Платта снижает Brier baseline с весами классов с 0,200 до 0,055, не меняя ранжирования, а настроенный CatBoost — обученный без весов — уже откалиброван.

3.2 Текст лотов: transfer learning против fine-tuning

Текст названий лотов	один, test	один, незнакомые тексты	добавлен к LightGBM на 20 признаках (0,311)
TF-IDF + логистическая регрессия (без переноса)	0,153	0,200	—
Замороженные rubert-tiny2 / e5-small / rubert-base + линейная проба	0,125 / 0,131 / 0,133	0,172 / 0,189 / 0,187	+0,036 / +0,028 / +0,025 (32 компоненты)
Дообученная rubert-tiny2 (среднее по 3 зёрнам)	0,154 ± 0,002	0,232 ± 0,005	+0,022 (стекинг), +0,010 (смешивание)

Замороженные кодировщики переносят общие знания языка (заметно выше 0,066 без модели), но в одиночку проигрывают TF-IDF: сходство в обычном русском — не риск закупки. Дообучение даёт лучшую текстовую модель на названиях, не встречавшихся при обучении (0,228–0,237 против 0,200), то есть модель выучивает лексику задачи. Но внутри табличной модели лучший способ добавить текст — 32 замороженные компоненты rubert-tiny2 (+0,036 [+0,025; +0,048]): они сообщают деревьям, *что* покупают, а одна дообученная оценка риска это теряет. Большие кодировщики для каталожных названий из пяти слов пользы не дали.

3.3 LLM

Qwen2.5-1.5B, дообученная через QLoRA, даёт PR-AUC на test **0,322** (ROC-AUC 0,808) — выше любой модели на 20 признаках, — но ниже LightGBM на тех же 40 000 строк и той же информации (0,334; разница −0,011 [−0,024; 0,000]) — как и ожидалось по TabLLM, где преимущество LLM на табличных данных исчезает при большом числе примеров (Hegselmann et al., 2023), — и ещё ниже LightGBM на всём train (0,350; −0,028 [−0,041; −0,015]). В среднем с бустингом (вес выбран на validation) она добавляет немного, но значимо: +0,008 [+0,005; +0,012] к LightGBM и +0,004 [+0,001; +0,007] к финальной модели, то есть её ошибки отличаются от ошибок деревьев.

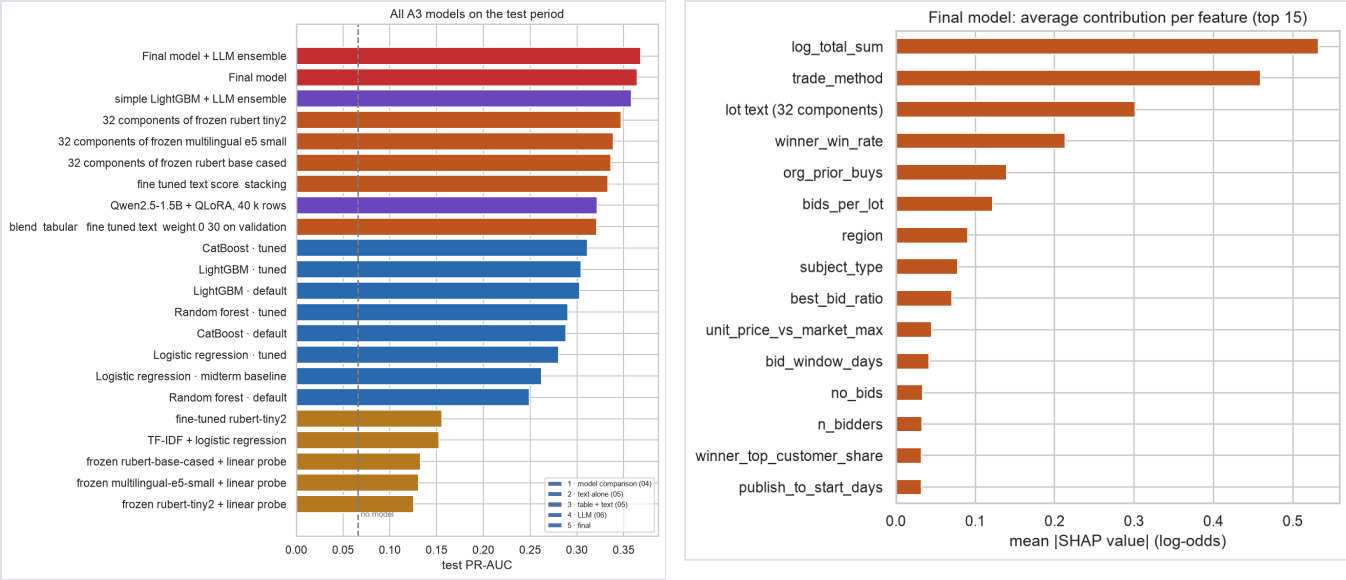


Рисунок 1. Слева: PR-AUC на test для каждой модели A3 (пунктир — без модели, 0,066). Справа: средний модуль значения SHAP признаков финальной модели (32 текстовые компоненты сложены в одну). Подписи на графиках — на английском.

3.4 Финальная модель, абляции и случай утечки

Модель (период test, 38 981 закупка)	PR-AUC [95 %]	ROC-AUC	P@1%	R@5%
Без модели	0,066	0,500	0,057	0,044
Baseline мидтерма: логистическая регрессия, 20 признаков	0,262 [0,246; 0,280]	0,792	0,504	0,263
Настроенный CatBoost, 20 признаков	0,311 [0,293; 0,331]	0,807	0,573	0,307
Qwen2.5-1.5B + QLoRA	0,322 [0,302; 0,342]	0,808	0,594	0,320
Финальная: CatBoost, 61 признак, откалибрована	**0,364 [0,343; 0,385]**	**0,827**	**0,715**	**0,337**
Финальная + LLM, ансамбль	0,368 [0,347; 0,390]	0,826	0,715	0,342

Финальная модель выбрана на validation из трёх кандидатов (CatBoost 0,405, простой LightGBM 0,400, LightGBM, заново настроенный на 61 признаке, 0,386 — подбор снова не помог). Для проверяющего, который проверяет 1 % закупок (≈ 390 за две тестовые недели), она находит ≈ **280 сорванных договоров вместо ≈ 196** у модели мидтерма. Прирост делится на два похожих шага: семейство модели (+0,049) и новая информация при том же CatBoost (+0,053). Абляции показывают, что эта информация — почти целиком **текст лотов** (−0,025 [−0,034; −0,016] без него), а признаки истории «заказчик–поставщик» и цены, предсказательные сами по себе, ничего не добавляют при наличии текста — что согласуется с выводом, что коррупционные «красные флаги» почти не связаны с проблемами исполнения (Decarolis & Giorgiantonio, 2022). SHAP ставит на первые места сумму (0,53), способ (0,46) и текст лотов (0,30), затем долю побед победителя в прошлом (0,21). Наибольшие улучшения — у закупок из одного источника после несостоявшейся закупки (подъём над долей срывов 2,2 → 8,0) и у самой дешёвой четверти закупок (2,3 → 3,6), самого слабого сегмента модели мидтерма.

Найденная и устранённая утечка. Ранняя версия ресёрча добавляла признаки «активности победителя», которые выглядели третьим по важности источником информации (+0,025). Победитель брался из таблицы договоров; проверка верха ранжированного списка показала, что подписант договора даже не подавал заявку в 27 % успешных, но в 63 % сорвавшихся закупок — после отказа договор уходит кому-то другому, поэтому *кто подписал* — отчасти уже исход. Определение победителя по объявлению или минимальной цене (с процедурным правилом при ничьей) убирает прирост полностью (−0,003 [−0,008; +0,002]). Утечка была в *связке* между записями, а не в каком-то одном поле — случай из типологии утечек Kaufman et al. (2012).

4. Гипотезы

Гипотеза (записана до экспериментов)	Результат
H4 Семейство модели важнее подбора	Подтверждена: семейство +0,04–0,05; подбор от 0 до +0,04, большой только при плохих настройках по умолчанию
H5 Новая информация важнее подбора	Подтверждена: тот же CatBoost, +0,053 от информации против +0,023 от подбора
H6 Текст полезен вместе с таблицей, а не сам по себе	Подтверждена: один текст в лучшем случае 0,156; самое большое добавление к таблице (+0,036)
H7 Дообучение делает текст сильнее TF-IDF	Частично: в целом наравне, явный выигрыш на незнакомых текстах; как признак лучше замороженные компоненты
H8 LLM ниже бустинга, но помогает в ансамбле	Подтверждена: −0,028 против бустинга на всех данных; +0,004 [+0,001; +0,007] в ансамбле
H9 Калибровка исправляет вероятности, не меняя ранжирования	Подтверждена: Brier 0,200 → 0,055 у baseline с весами; PR-AUC не изменился

5. Ограничения

Все модели обучены на январе–феврале 2024 и проверены на второй половине марта: закупки в конце года, когда бюджет осваивают в спешке, могут срываться чаще и по другим причинам. Метка — итоговый статус на портале, а расторжения «по соглашению сторон» включают безобидные случаи (строгая метка сохранена в данных). Используется только информация, известная в момент выбора победителя, что намеренно исключает самые сильные сигналы прототипа на правилах (исполнение договора, платежи, штрафы): они и есть сам исход. Результаты на видеокарте (дообучение, LLM) могут отличаться в третьем знаке на другом железе.

6. Выводы

Лучшая модель и лучшая информация вносят примерно поровну: градиентный бустинг и новая информация дают каждый около 0,05 PR-AUC, а подбор гиперпараметров сверх разумных настроек по умолчанию добавляет мало или ничего. Самая ценная новая информация — текст того, что покупают, и лучший способ передать его табличной модели — компактный замороженный эмбеддинг, а не дообученная оценка; дообучение окупается, когда тексты новые. LLM на 1,5 млрд параметров, дообученная через QLoRA на бесплатной видеокарте, учит задачу, но не обгоняет бустинг на сотнях тысяч строк; она полезна как второе мнение в ансамбле. Финальная модель ранжирует сорванные договоры с PR-AUC 0,364 и откалиброванными вероятностями и находит примерно на 40 % больше срывов, чем модель мидтерма, при том же бюджете проверок. Методологически главный урок: подозрительно большой прирост нужно проследить до момента, когда становится известно каждое значение — и каждая связка между записями.

Литература

Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. *KDD*, 2623–2631.

Decarolis, F., & Giorgiantonio, C. (2022). Corruption red flags in public procurement: New evidence from Italian calls for tenders. *EPJ Data Science*, 11(1).

Dettmers, T., Pagnoni, A., Holtzman, A., & Zettlemoyer, L. (2023). QLoRA: Efficient finetuning of quantized LLMs. *NeurIPS*.

Fazekas, M., & Kocsis, G. (2020). Uncovering high-level corruption: Cross-national objective corruption risk indicators using public procurement data. *British Journal of Political Science*, 50(1), 155–164.

Hegselmann, S., Buendia, A., Lang, H., Agrawal, M., Jiang, X., & Sontag, D. (2023). TabLLM: Few-shot classification of tabular data with large language models. *AISTATS*.

Hu, E. J., Shen, Y., Wallis, P., et al. (2022). LoRA: Low-rank adaptation of large language models. *ICLR*.

Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM TKDD*, 6(4), 15.

Ke, G., Meng, Q., Finley, T., et al. (2017). LightGBM: A highly efficient gradient boosting decision tree. *NeurIPS*.

Lundberg, S. M., Erion, G., Chen, H., et al. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2, 56–67.

Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased boosting with categorical features. *NeurIPS*.