Что на самом деле улучшает прогноз срыва договоров

Assignment 3 · Обучение и дообучение моделей · Tender Risk ML · Азиз Абдулин

ЗАДАЧА

Та же, что в мидтерме: в момент выбора победителя предсказать, будет ли договор расторгнут или не заключён. Вопрос А3 — что даёт прирост: модель, настройка или новая информация.

ГЛАВНЫЙ ВЫВОД

Сильная модель и новая информация (прежде всего текст лотов) дали примерно по +0,05 PR-AUC. Подбор гиперпараметров почти ничего не добавил.

0,262 → 0,364

PR-AUC на test: мидтерм → финальная модель

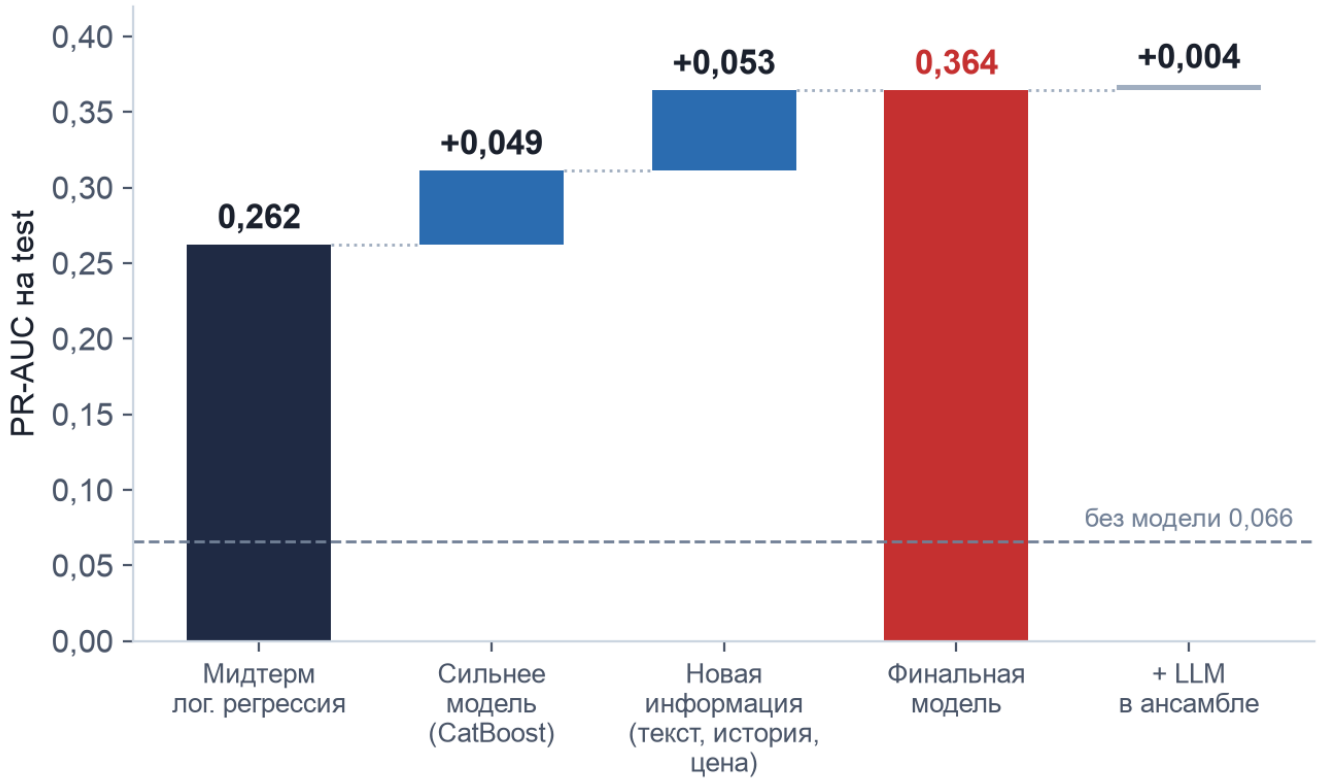
72 %

срывов среди 1 % самых рискованных закупок (у мидтерма 50 %)

≈ 280 вместо 196

найденных срывов, если проверить 1 % закупок за две недели test

Прирост поровну дали сильная модель и новая информация



PR-AUC на test (16–31 марта 2024). Данные, разбиение по времени и метрики — как в мидтерме: 358 789 закупок, срывов 6,6 %.

Что сделано в A3

04 **Четыре модели, подбор, порог, калибровка**
GridSearch и Optuna · критерии 1, 2, 6

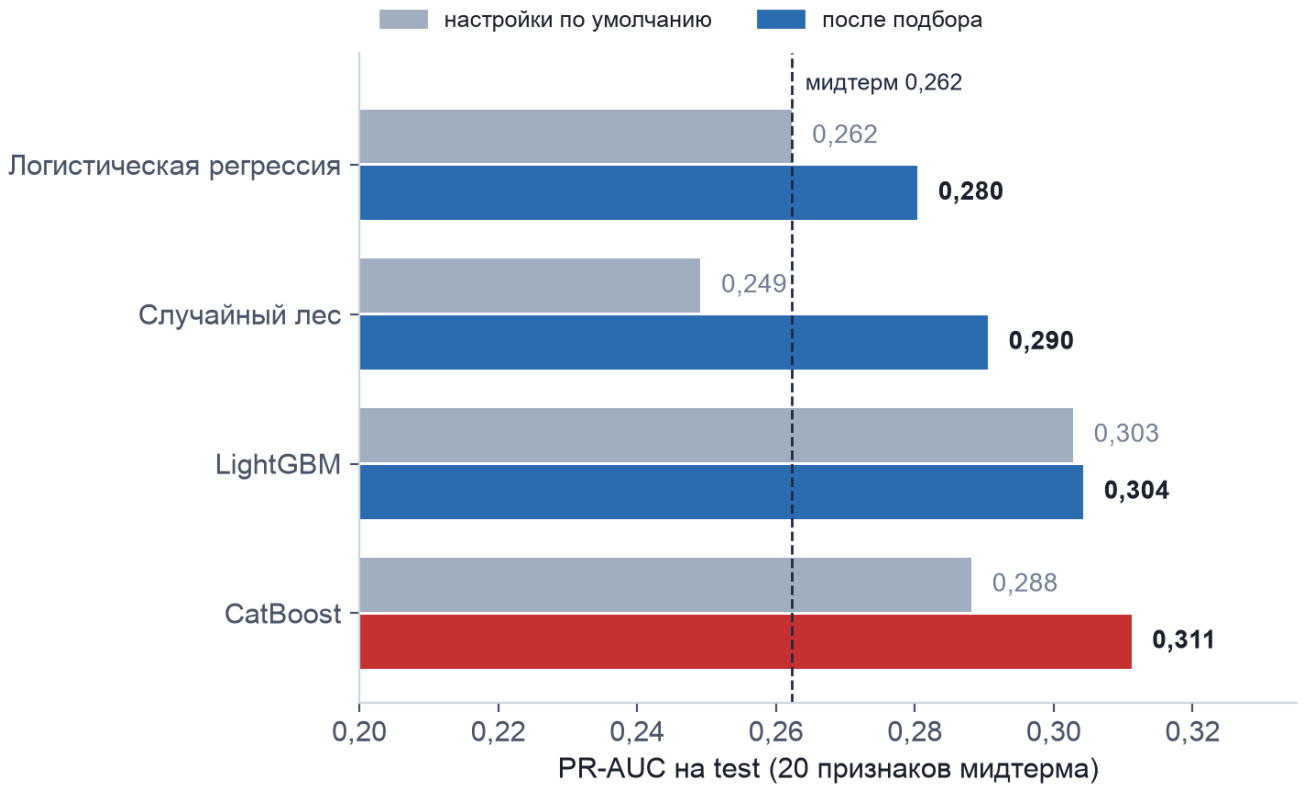
05 **Текст лотов: перенос и дообучение**
3 замороженных кодировщика, дообученный rubert-tiny2 · критерии 3, 4

06 **LLM с QLoRA на Kaggle**
Qwen2.5-1.5B читает карточку закупки · критерий 5

07 **Финальная модель и разбор**
общая таблица, абляции, SHAP, утечка, сегменты · критерии 7–9

Подбор гиперпараметров: от +0,001 (LightGBM) до +0,04 (случайный лес). Потолок задаёт информация, а не настройки.

Бустинг сильнее регрессии, подбор добавляет мало



Как сравнивали

4 модели на тех же 20 признаках, что в мидтерме. Подбор только на validation (1–15 марта), test открывается один раз.

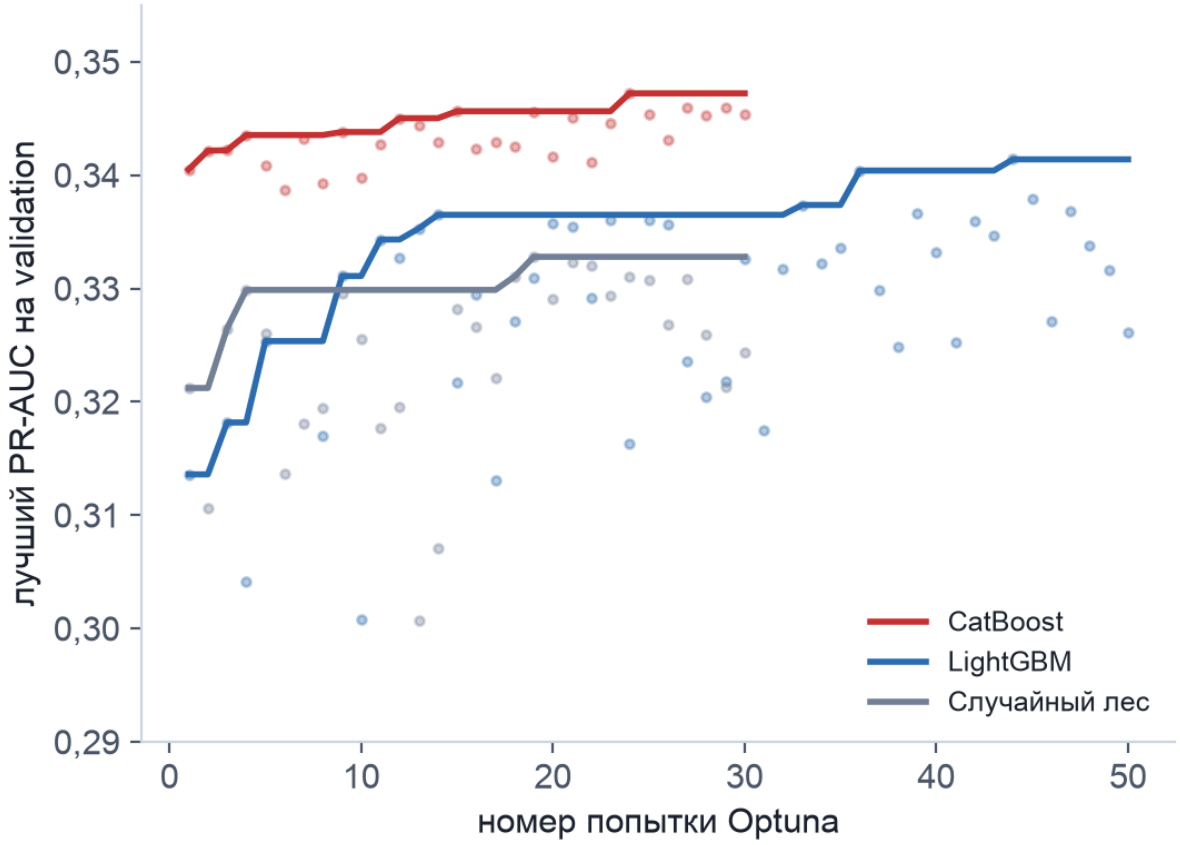
Как подбирали

Логистическая регрессия — GridSearch, 42 сочетания (C, штраф, веса классов). Лес, LightGBM и CatBoost — Optuna (TPE), 30–50 попыток.

Вывод

Лучшая — CatBoost после подбора: 0,311 против 0,262 (+0,049, интервал [+0,039; +0,059]). LightGBM по умолчанию уже 0,303: подбор дал +0,001.

Подбор выходит на плато, калибровка чинит вероятности



Точки — отдельные попытки, линия — лучший результат к этой попытке. CatBoost достиг максимума на 24-й попытке из 30, LightGBM — на 44-й из 50.

Порог решения (CatBoost после подбора)

Порог	Помечено	Точность	Полнота
0,5 по умолчанию	0,6 %	0,60	0,05
макс. F1 на validation (0,188)	**8,0 %**	**0,34**	**0,41**
бюджет 5 % (0,249)	4,8 %	0,41	0,30

Калибровка: масштабирование Платта

0,415 → 0,069

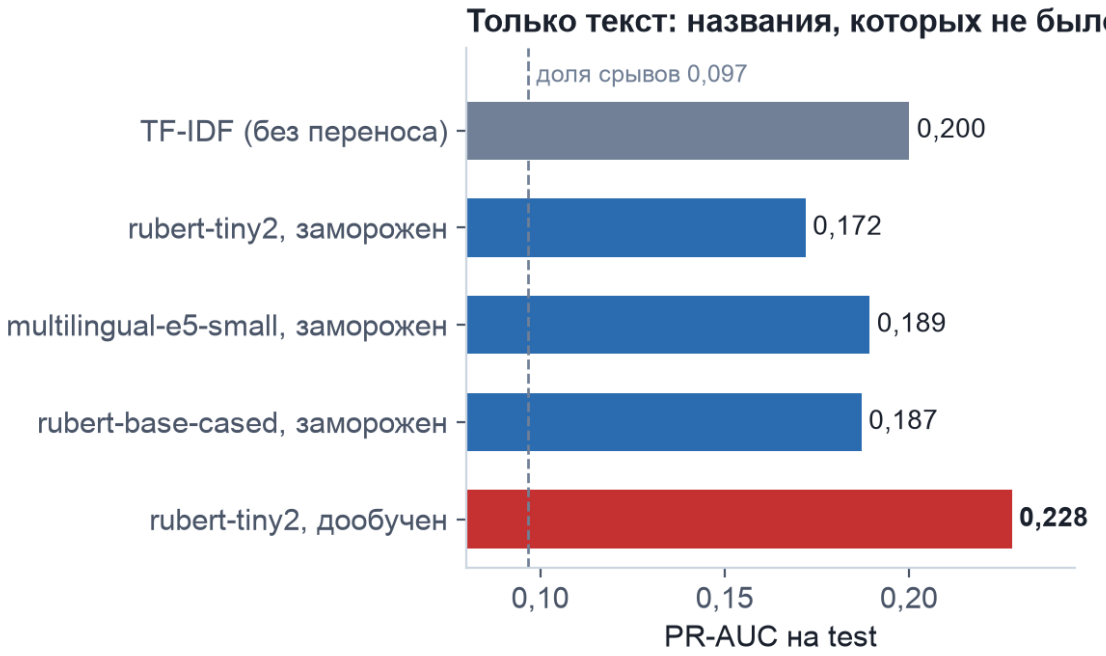
средняя оценка модели мидтерма при доле срывов 0,066

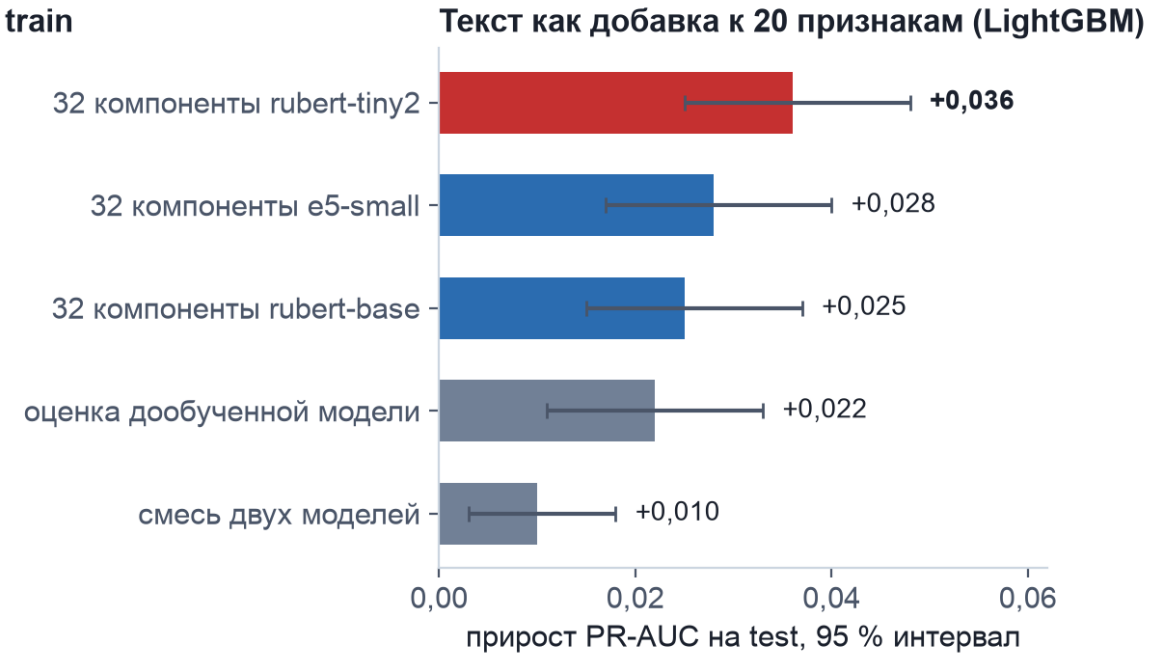
0,200 → 0,055

Brier score мидтерма; ранжирование и PR-AUC не меняются

Isotonic-калибровка создаёт ничьи в оценках и снижает PR-AUC (0,311 → 0,303), поэтому выбран Платт.

Текст: дообучение лучше всех читает незнакомые названия





Transfer learning

Три замороженных кодировщика и логистическая регрессия поверх. Сами по себе слабее TF-IDF: названия лотов короткие и шаблонные.

Fine-tuning rubert-tiny2

Дообучение всей модели: lr $5 \cdot 10^{-5}$, батч 64, 2 эпохи, AdamW, взвешенная кросс-энтропия. Лучшая на незнакомых названиях: 0,228 против 0,200.

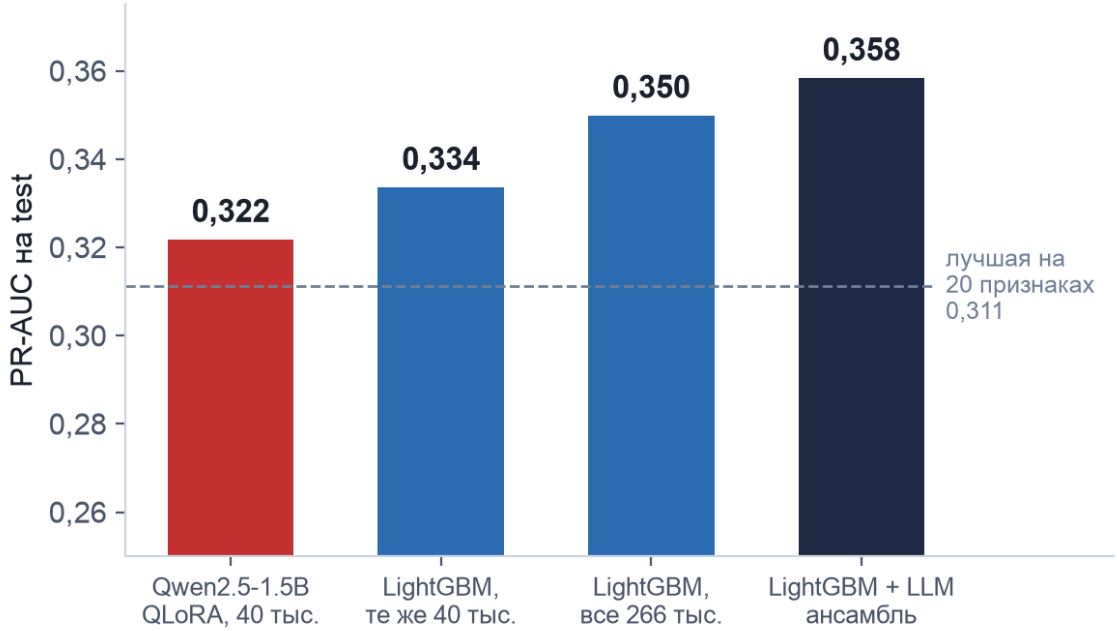
Текст вместе с таблицей

Лучше всего — 32 компоненты замороженного rubert-tiny2 в LightGBM: +0,036. Они и вошли в финальную модель.

LLM с QLoRA: слабее бустинга, но полезна в ансамбле

Конфигурация

Базовая модель	**Qwen2.5-1.5B + голова классификации**
Квантование	**4 бита NF4, двойное квантование**
LoRA: r / α / dropout	**16 / 32 / 0,05**
Где адаптеры	**все 7 линейных проекций слоя**
Обучаемые параметры	**18,5 млн из 1,5 млрд (1,2 %)**
Обучение	**40 тыс. карточек, 1 эпоха, lr $2 \cdot 10^{-4}$**
Видеокарта	**Kaggle T4: 2,2 ч обучение, 1,3 ч оценка**



Почему не полное дообучение

Полное дообучение 1,5 млрд параметров требует ≈ 25 ГБ памяти и не помещается в T4 (16 ГБ). QLoRA — пик 2,7 ГБ, адаптер ≈ 70 МБ.

На тех же 40 тыс. строк LightGBM выше на 0,011 [−0,024; 0,000]. В ансамбле LLM добавляет +0,008 [+0,005; +0,012]: ошибки моделей разные.

Все модели на одном test

Модель	Что видит	PR-AUC [95 %]	ROC-AUC	P@1 %
Без модели (доля срывов)	—	0,066	0,500	0,057
Лог. регрессия · мидтерм	20 признаков	0,262 [0,246; 0,280]	0,792	0,504
CatBoost после подбора	20 признаков	0,311 [0,293; 0,331]	0,807	0,573
Дообученный rubert-tiny2	только названия лотов	0,156 [0,146; 0,167]	0,697	0,242
Qwen2.5-1.5B + QLoRA	карточка закупки	0,322 [0,302; 0,342]	0,808	0,594
LightGBM + текст	20 признаков + текст	0,347 [0,327; 0,368]	0,822	0,671
Финальная модель · CatBoost	**61 признак**	**0,364 [0,343; 0,385]**	**0,827**	**0,715**
Финальная + LLM	61 признак + LLM	0,368 [0,347; 0,390]	0,826	0,715

Полная таблица из 25 строк — в ноутбуке 07 и results/a3_07/all_models_test.csv.

≈ 280

срывов найдёт проверка 1 % закупок (≈ 390 за две недели) по финальной модели

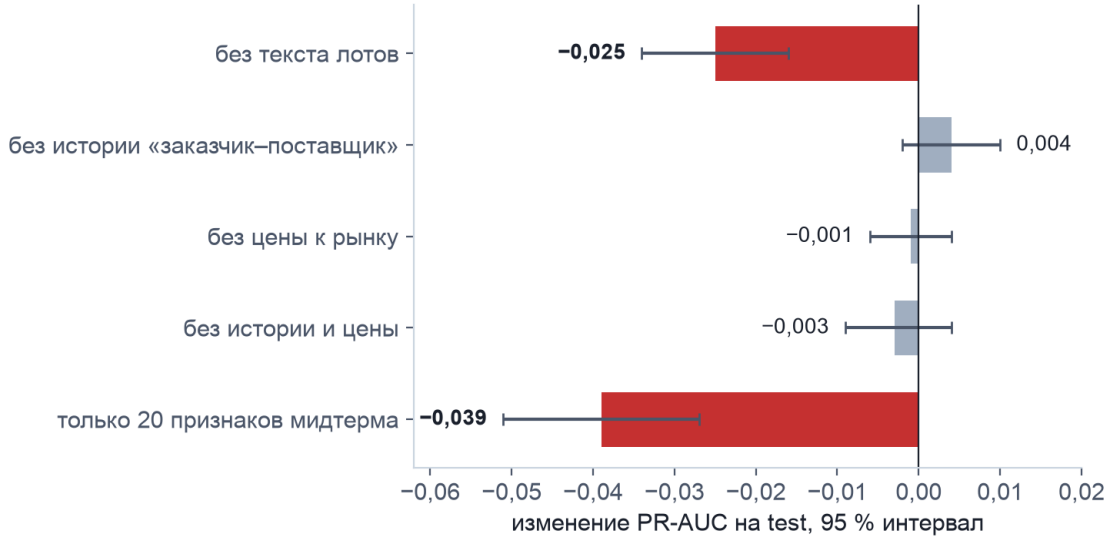
мидтерм ≈ 196 · случайный выбор ≈ 26

Как читать

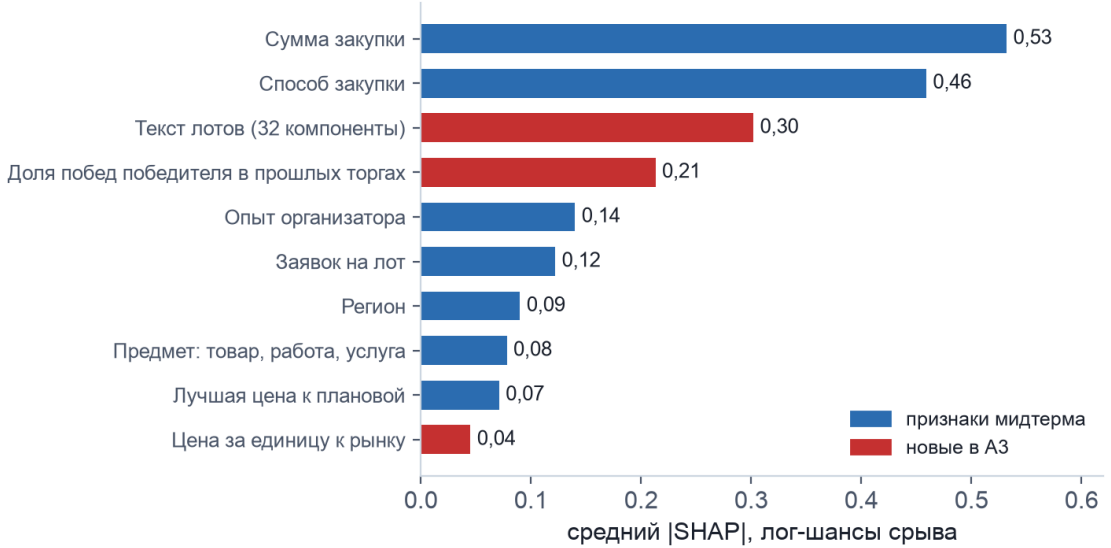
P@1 % — доля срывов среди 1 % закупок с наибольшей оценкой. Интервал — бутстрэп, 1 000 перевыборок.

Почти весь новый сигнал — текст лотов

Абляции: убираем группу и переобучаем



SHAP: что двигает предсказания



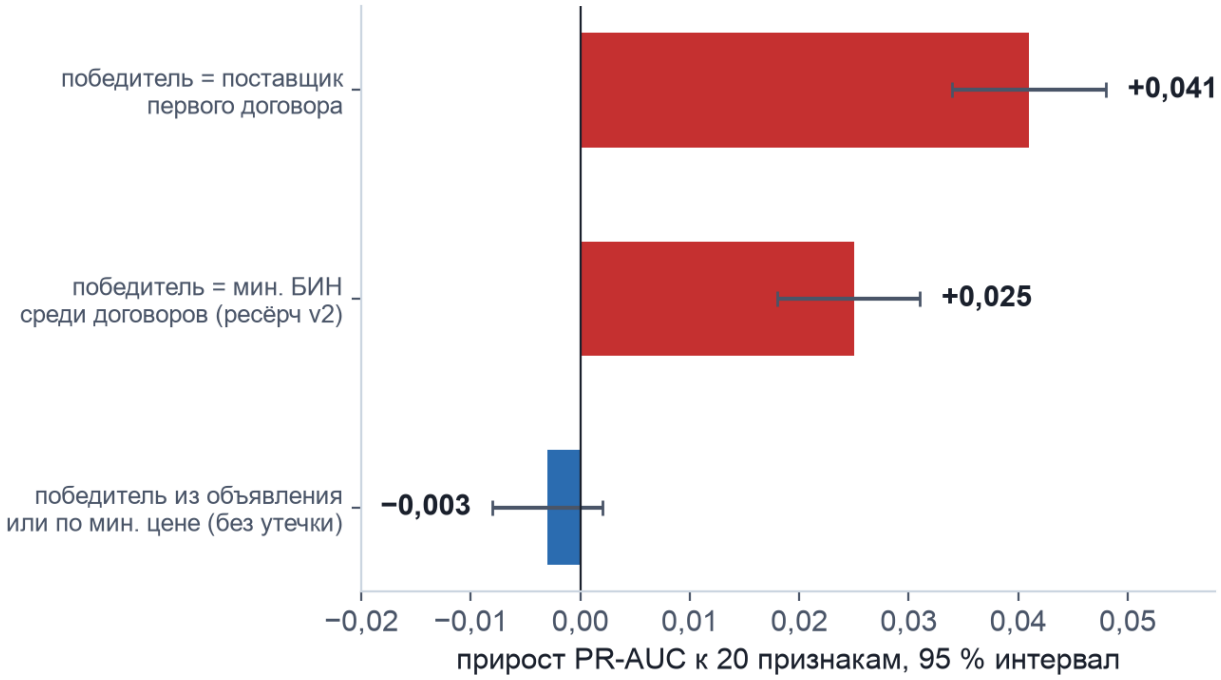
Абляции

Без текста −0,025: интервал не включает ноль. История и цена поверх текста ≈ 0, хотя по отдельности предсказательны.

Важный ≠ незаменимый

Доля побед победителя — 4-я по SHAP, но без неё модель берёт ту же информацию из других признаков. Сумма и способ закупки, как в мидтерме, — главные.

Случай утечки: «победитель» из таблицы договоров



Признаки активности победителя (заявки за 30 дней, ИП или нет) при трёх определениях победителя. Красные — с утечкой.

27 % и 63 %

закупок, где подписант договора даже не подавал заявку: среди успешных и среди сорвавшихся

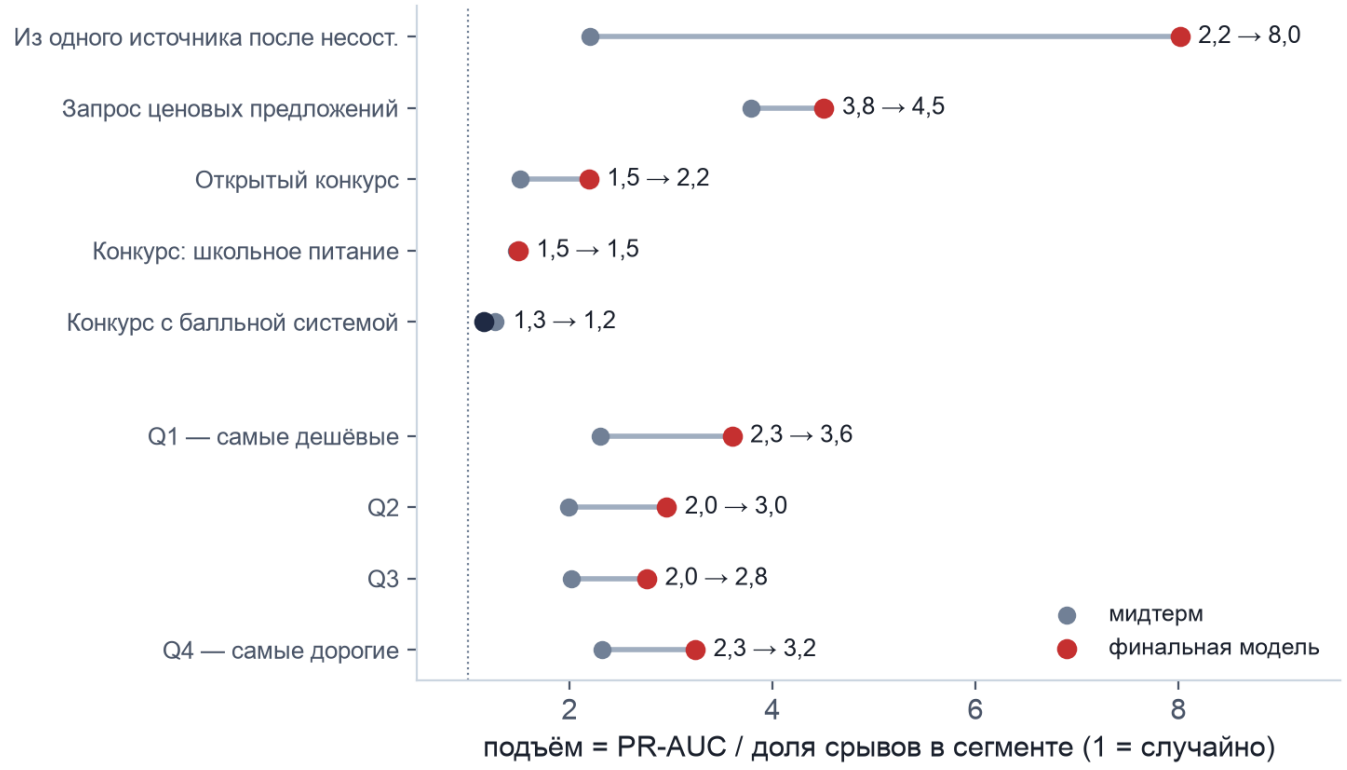
Почему это утечка

Если победитель отказался подписывать, договор уходит другому участнику или заключается вне конкурса. Кто подписал — уже часть исхода.

Урок

Слишком сильный признак — проверить верх списка вручную и проследить, когда значение становится известно. Без утечки прирост равен нулю.

Где модель помогает больше всего



1 **Из одного источника после несостоявшейся**
подъём 2,2 → 8,0: срывов здесь всего 2 %, и мидтерм их почти не различал

2 **Самые дешёвые закупки**
2,3 → 3,6: слабое место мидтерма — при рабочем пороге он не находил там ни одного срыва

3 **Конкурсы с балльной системой**
≈ 1,2: почти случайно; всего 624 закупки в test — трудный сегмент

Как читать

Подъём = PR-AUC / доля срывов в сегменте; 1 — случайный выбор. Сегменты с разной долей срывов нельзя сравнивать по самому PR-AUC.

Выводы и ограничения

ЧТО ПОКАЗАЛ А3

0,364

PR-AUC финальной модели на test (мидтерм 0,262); ROC-AUC 0,827; вероятности откалиброваны

+0,05 ×2

дали сильная модель и новая информация; подбор гиперпараметров почти ничего

0,228

у дообученного rubert-tiny2 на незнакомых названиях — лучше TF-IDF; LLM полезна в ансамбле

1 утечка

найдена и исправлена: победитель из договора — это уже исход

ОГРАНИЧЕНИЯ И ВОСПРОИЗВОДИМОСТЬ

1. **Один квартал данных**
   декабрьская спешка с бюджетом модели не знакома
2. **Метка — статус на портале**
   включает расторжения по соглашению сторон
3. **LLM на 40 тыс. строк**
   больше не позволило время GPU
4. **Воспроизводимость**
   зерно 42; ноутбуки из build_*.py; данные — релиз data-v1; LLM — скрипт для Kaggle